



Processos, Threads, Escalonamento e Inferência Local com Ollama



SISTEMAS OPERACIONAIS – ATIVIDADE 1 (AV1)

Discente: Mariana de Jesus Silva

Trilha A — Chat Local: Ollama + Open WebUI

Modelo: Llama 3.2 3B



OBJETIVO E ARQUITETURA

Objetivo

- Processos e threads
- Comunicação e portas
- Chamadas de sistema
- Uso de CPU e memória
- Desempenho
- Limitações do ambiente

Arquitetura

Usuário → Navegador → Open WebUI → Ollama → Llama 3.2 3B → CPU/RAM

Open WebUI: 8080

Ollama: 11434

AMBIENTE EXPERIMENTAL

Hardware

- Ubuntu 26.04.1 LTS
- WSL2
- Intel Core i3-10110U
- 2 cores / 4 threads
- 5,7 GiB RAM
- 2 GiB swap
- GPU NVIDIA não disponível no WSL

Software

- Ollama 0.34.2
- Open WebUI v0.11.4
- Python 3.11

```
mariana@Lenovo:~$ uname -a
Linux Lenovo 6.18.33.2-microsoft-standard-WSL2 #1 SMP PREEMPT_DY
NOMIC Thu Jun 18 21:54:43 UTC 2026 x86_64 GNU/Linux
mariana@Lenovo:~$ cat /etc/os-release
PRETTY_NAME="Ubuntu 26.04.1 LTS"
NAME="Ubuntu"
VERSION_ID="26.04"
VERSION="26.04.1 LTS (Resolute Raccoon)"
VERSION_CODENAME=resolute
ID=ubuntu
ID_LIKE=debian
HOME_URL="https://www.ubuntu.com/"
SUPPORT_URL="https://help.ubuntu.com/"
BUG_REPORT_URL="https://bugs.launchpad.net/ubuntu/"
PRIVACY_POLICY_URL="https://www.ubuntu.com/legal/terms-and-polic
ies/privacy-policy"
UBUNTU_CODENAME=resolute
LOGO=ubuntu-logo
```

```
mariana@Lenovo:~$ free -h
```

	total	used	free	shared	buff/cache	available
Mem:	5.7Gi	474Mi	4.4Gi	3.5Mi	980Mi	5.2Gi
Swap:	2.0Gi	0B	2.0Gi			

AMBIENTE EXPERIMENTAL

```
mariana@Lenovo:~$ lscpu
Architecture:          x86_64
CPU op-mode(s):        32-bit, 64-bit
Address sizes:         39 bits physical, 48 bits virtual
Byte Order:            Little Endian
CPU(s):                4
On-line CPU(s) list:   0-3
Vendor ID:             GenuineIntel
Model name:            Intel(R) Core(TM) i3-10110U CPU @ 2.10GHz
                       6
CPU family:            142
Model:                 2
Thread(s) per core:    2
Core(s) per socket:    2
Socket(s):             1
Stepping:              12
BogoMIPS:              5184.01
Flags:                 fpu vme de pse tsc msr pae mce cx8
                       apic sep mtrr pge mca cmov pat pse3
                       6 clflush mmx fxsr sse sse2 ss ht s
                       yscall nx pdpe1gb rdtscp lm arch_pe
                       rfmon rep_good nopl xtopology cpuid
                       tsc_known_freq pni pclmulqdq vmx s
                       sse3 fma cx16 pdcmm pcid sse4_1 sse4
                       _2 movbe popcnt aes xsave avx f16c
                       rdrand hypervisor lahf_lm abm 3dnow
                       prefetch ssbd ibrs ibpb stibp ibrs_
                       enhanced tpr_shadow ept vpid ept_ad
                       fsgsbase bmi1 avx2 smep bmi2 erms
                       invpcid rdseed adx smap clflushopt
                       xsaveopt xsavec xgetbv1 xsaves vnmi
                       md_clear flush_l1d arch_capabilities

Virtualization features:
Virtualization:        VT-x
Hypervisor vendor:     Microsoft
Virtualization type:    full
Caches (sum of all):
```

```
Caches (sum of all):
L1d:                   64 KiB (2 instances)
L1i:                   64 KiB (2 instances)
L2:                    512 KiB (2 instances)
L3:                    4 MiB (1 instance)
NUMA:
NUMA node(s):          1
NUMA node0 CPU(s):     0-3
Vulnerabilities:
Gather data sampling:   Unknown: Dependent on hypervisor st
                        atus
                        Not affected
Ghostwrite:             Mitigation; Aligned branch/return t
                        hunks
Indirect target selection: KVM: Mitigation: Split huge pages
                        Not affected
                        Not affected
                        Not affected
Itlb multihit:          Mitigation; Clear CPU buffers; SMT
                        Host state unknown
L1tf:                   Not affected
Mds:                    Not affected
Meltdown:               Not affected
Mmio stale data:        Mitigation; Clear CPU buffers; SMT
                        Not affected
Old microcode:          Not affected
Reg file data sampling: Not affected
Retbleed:               Mitigation; Enhanced IBRS
                        Not affected
Spec rstack overflow:   Mitigation; Speculative Store Bypas
                        s disabled via prctl
Spec store bypass:      Mitigation; usercopy/swapgs barrier
                        s and __user pointer sanitization
Spectre v1:             Mitigation; Enhanced / Automatic IB
                        RS; IBPB conditional; PBR SB-eIBRS S
                        W sequence; BHI SW loop, KVM SW loo
                        p
Spectre v2:             Unknown: Dependent on hypervisor st
                        atus
Srbds:                  Not affected
Tsa:                    Not affected
Tsx async abort:        Not affected
Vmscape:                Not affected
```

MODELO E EXECUÇÃO LOCAL

Llama 3.2 3B

- 3,2 bilhões de parâmetros
- GGUF
- Q4_K_M
- Contexto: 131.072 tokens
- Tamanho: ~1,9 GB
- Ollama: llama3.2:3b

```
mariana@Lenovo:~$ ollama list
NAME          ID          SIZE    MODIFIED
llama3.2:3b   a80c4f17acd5 2.0 GB  2 days ago
```

```
mariana@Lenovo:~$ ollama show llama3.2:3b
Model
architecture      llama
parameters         3.2B
context length     131072
embedding length   3072
quantization       Q4_K_M

Capabilities
completion
tools

Parameters
stop               "<|start_header_id|>"
stop               "<|end_header_id|>"
stop               "<|eot_id|>"

License
LLAMA 3.2 COMMUNITY LICENSE AGREEMENT
Llama 3.2 Version Release Date: September 25, 2024
...
```

DEMONSTRAÇÃO DA EXECUÇÃO

Execução local

Open WebUI → Ollama → Llama 3.2 3B

Demonstração

Pergunta utilizada:

“Explique em poucas frases o que é uma thread em um sistema operacional.”

```
mariana@Lenovo:~$ ollama run llama3.2:3b "Explique em poucas frases  
o que é uma thread em um sistema operacional."  
Uma thread é uma unidade de execução em um sistema operacional que e  
xecuta uma parte do programa. Ela é semelhante a um processo, mas  
compartilha recursos do sistema e tem menor prioridade.
```

PROCESSOS, THREADS E COMUNICAÇÃO

Processos observados

- ollama
- llama-server
- open-webui

Comunicação

Open WebUI: 127.0.0.1:8080

Ollama: 127.0.0.1:11434

Coleta representativa

llama-server

- 11 threads
- CPU: 42,2%
- Memória: 42,5%

PROCESSOS, THREADS E COMUNICAÇÃO

```
mariana@Lenovo:~$ ps -eo pid,ppid,stat,ni,pri,psr,pcpu,pmem,nlwp,comm --sort=-pcpu
PID      PPID  STAT  NI PRI  PSR  %CPU  %MEM  NLWP  COMMAND
1         0  Ss    0  19   2   0.1   0.2    1  systemd
131       1  Ssl   0  19   0   0.0   0.4   10  ollama
90        1  Ss    0  19   3   0.0   0.2    1  systemd-udev
126       1  Ss    0  19   1   0.0   0.4    1  networkd-dispat
47        1  S<s   -1  20   1   0.0   0.2    1  systemd-journal
242       1  Ssl   0  19   0   0.0   0.5    2  unattended-upgr
351      346  Ss    0  19   2   0.0   0.0    1  bash
411       1  Ss    0  19   3   0.0   0.2    1  systemd
82        1  Ss    0  19   0   0.0   0.2    1  systemd-resolve
146       1  Ss    0  19   1   0.0   0.1    1  systemd-logind
172       1  Ssl   0  19   0   0.0   0.0    4  rsyslogd
113       1  Ss    0  19   0   0.0   0.0    1  dbus-daemon
346      345  S     0  19   1   0.0   0.0    1  Relay(351)
205      111  S     0  19   2   0.0   0.1    1  chronyd
111       1  Ss    0  19   2   0.0   0.0    1  chronyd-starter
440      355  Ss+   0  19   1   0.0   0.0    1  bash
355       2  Ss    0  19   0   0.0   0.0    1  login
256       1  Ss+   0  19   2   0.0   0.0    1  agetty
112       1  Ss    0  19   0   0.0   0.0    1  cron
2        1  Sl+   0  19   0   0.0   0.0    2  init-systemd(Ub
7        2  Sl+   0  19   2   0.0   0.0    2  init
218      205  S     0  19   3   0.0   0.0    1  chronyd
345       2  Ss    0  19   2   0.0   0.0    1  SessionLeader
413      411  S     0  19   1   0.0   0.0    1  (sd-pam)
704      351  R+    0  19   0   0.0   0.0    1  ps
mariana@Lenovo:~$ ss -lntp | grep -E '11434|8080'
LISTEN 0      4096      127.0.0.1:11434      0.0.0.0:*
```

CHAMADAS DE SISTEMA

6.080 chamadas de sistema.

382 ocorrências classificadas como erro pelo strace.

% time	seconds	usecs/call	calls	errors	syscall
73.06	2.105910	1385	1520	300	futex
11.48	0.330986	303	1089	4	epoll_pwait
10.42	0.300303	194	1546		nanosleep
1.67	0.048073	91	526	6	write
0.81	0.023374	82	285		ioctl
0.45	0.013050	63	204	47	read
0.29	0.008243	128	64	4	rt_sigreturn
0.27	0.007665	119	64		tgkill
0.23	0.006741	105	64		getpid
0.15	0.004188	46	91		mmap
0.13	0.003853	96	40		pread64
0.13	0.003841	60	63		rt_sigprocmask
0.13	0.003710	46	80		sched_yield
0.11	0.003223	358	9		clone3
0.09	0.002503	80	31		sched_getaffinity
0.09	0.002465	2465	1		execve
0.08	0.002442	66	37		prctl
0.06	0.001666	14	114		rt_sigaction

EXPERIMENTOS

3 configurações — 12 execuções

Configuração	Característica
C1	num_ctx=4096, sequencial
C2	num_ctx=4096, 2 requisições simultâneas
C3	num_ctx=2048, sequencial

Entradas: curta e longa.

Repetições: 2 por cenário.

EXPERIMENTOS

```
mariana@Lenovo:~$ ~/experimentos.sh
```

```
=== C1 ===
```

```
=== C2 ===
```

```
=== C3 ===
```

```
=== EXPERIMENTOS CONCLUÍDOS ===
```

```
execucao,configuracao,entrada,repeticao,tempo_total_s,load_s,prompt_tokens,output_tokens,tokens_s,erro
```

```
1,C1,Curta,1,25.151,14.401,53,34,5.23,OK
```

```
2,C1,Curta,2,13.861,0.015,53,64,4.78,OK
```

```
3,C1,Longa,1,18.942,0.009,117,64,5.14,OK
```

```
4,C1,Longa,2,12.741,0.005,117,64,5.14,OK
```

```
6,C2,Curta,2,13.041,0.002,53,64,5.04,OK
```

```
5,C2,Curta,1,27.138,0.003,53,64,4.60,OK
```

```
7,C2,Longa,1,13.191,0.004,117,64,4.97,OK
```

```
8,C2,Longa,2,27.371,0.004,117,64,4.59,OK
```

```
9,C3,Curta,1,22.423,13.056,53,32,5.85,OK
```

```
10,C3,Curta,2,11.722,0.003,53,64,5.62,OK
```

```
11,C3,Longa,1,20.622,0.002,117,64,4.52,OK
```

```
12,C3,Longa,2,13.234,0.054,117,64,4.97,OK
```

RESULTADOS

Tempo total médio

C1 – 17,67 s

C2 – 20,19 s

C3 – 17,00 s

Tokens/s médio

- C1: 5,07
- C2: 4,80
- C3: 5,24

Resultado geral

12/12 execuções sem erro.

CONCLUSÕES E LIMITAÇÕES

Conclusões

- Ollama + Open WebUI funcionaram localmente.
- Processos e threads foram observados.
- Portas locais foram identificadas.
- Chamadas de sistema foram coletadas com `strace`.
- Foram realizadas 12 execuções.
- Não ocorreram erros nas execuções experimentais.

Limitações

- 2 cores / 4 threads
- 5,7 GiB RAM
- Sem GPU NVIDIA disponível no WSL
- TTFT não medido separadamente
- Resultados específicos deste ambiente

REPOSITÓRIO E ENCERRAMENTO

Repositório

SO_UFS_2026_2_Silva_Mariana

Contém:

- Relatório
- README
- Scripts
- Resultados
- Evidências
- Configurações
- VIDEO.md

Vídeo

URL: https://youtu.be/SH9_ovTPqbU